Veri Bilimi için Matematik ve İstatistik

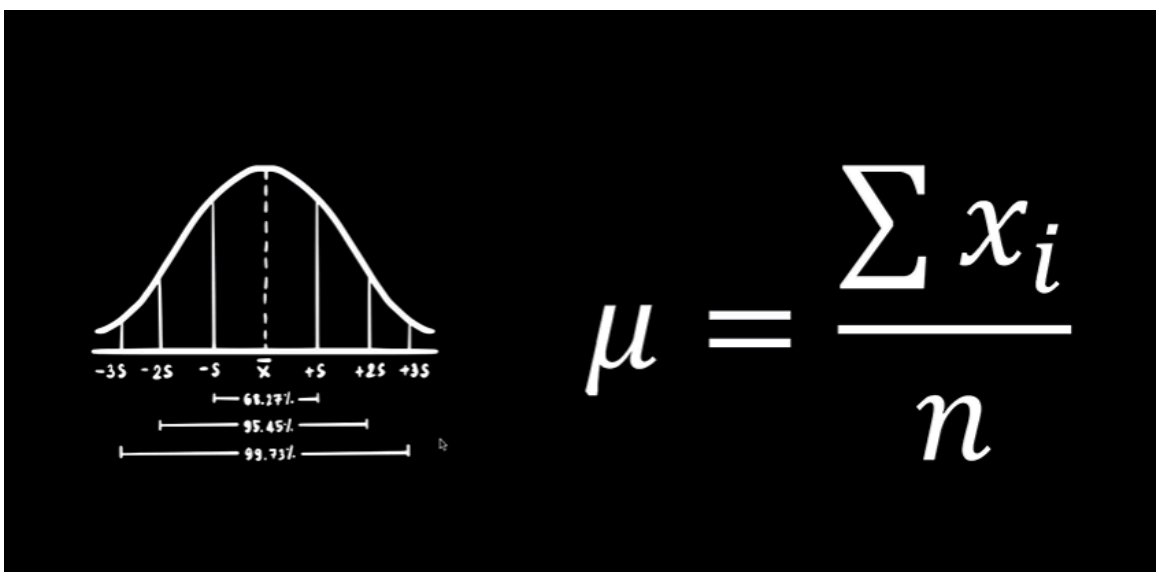

İstatistik Nedir?

👉 **İstatistik**, verilerin **toplanması, düzenlenmesi, özetlenmesi, analiz edilmesi** ve bu analizlerden **yorum yapma, çıkarımda bulunma** süreçlerini inceleyen bilim dalıdır.

Birkaç temel noktayı açalım:

1. **Veri toplama:**

   Araştırma, gözlem, anket, deney veya kayıtlar yoluyla bilgi toplanır.

   (Örn: Bir sınıftaki öğrencilerin yaşlarını öğrenmek için veri toplamak).

2. **Veri düzenleme ve özetleme:**

   Tablo, grafik, ortalama, medyan, standart sapma gibi ölçülerle veriler düzenlenir ve özetlenir.

   (Örn: "Bu sınıfın yaş ortalaması 20'dir" demek).

3. **Analiz ve çıkarım:**

   Sadece elimizdeki veriyi tanımlamakla kalmaz, aynı zamanda genelleme yapmaya da çalışır.

   (Örn: Bir ankette 100 kişiye sorulan soruya verilen cevaplardan, tüm toplumun eğilimi tahmin edilir).

4. **Karar verme:**

   Belirsizlik altında daha doğru kararlar almak için istatistik kullanılır.

   (Örn: Bir şirket, müşteri verilerini analiz ederek hangi ürüne yatırım yapacağını belirler).

🔑 Özetle:

İstatistik, **veriyi bilgiye dönüştüren** ve belirsizlik içinde **akılcı kararlar almamızı sağlayan** bir araçtır.

İstatistik Türleri Nelerdir?

İstatistik temel olarak 2'ye ayrılır.

1. **Betimsel(Descriptive)**
2. **Çıkarımsal(Inferential)**

Betimsel(Descriptive): Herhangi bir veri setinde ortalama, mod alma, standartsapmasını alma gibi işlemler yapıldığında burada betimsel istatistik kullanılır. Yani durumu ortaya koyuyoruz.

Çıkarımsal(Inferential): Bir veri setinde bulunan(örneğin sınıf notları) var olan veri setinden yeni notları tahmin etmeye yarar. Yani bir sonuç ortaya çıkarır.

Popülasyon ve Örneklem Nedir?

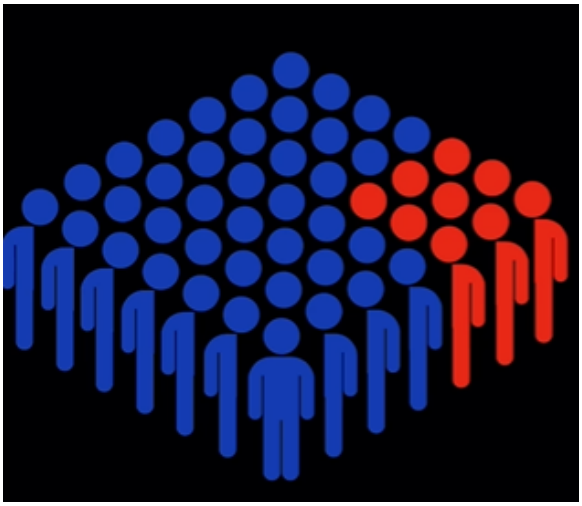

Popülasyon, Ana Kitle (Population):

- İncelemek istediğimiz bütün bireylerin, olayların veya nesnelerin oluşturduğu **tam kümedir**.
- Yani araştırmanın ilgilendiği tüm grubun tamamına verilen isimdir.

Örneklem (Sample):

- Popülasyonun tamamını incelemek çoğu zaman **imkânsız veya çok maliyetli** olabilir.
- Bunun yerine, popülasyonu temsil edecek şekilde **seçilen daha küçük bir grup** incelenir. İşte bu gruba örneklem denir.

- Yanlı sonuçlar çıkmaması için ana kitleyi tanımlayan farklı grupları seçmek ve rastgele seçimler yaparak örneklemi belirlemek önemlidir.

📊 İlişkiyi Şöyle Düşünebiliriz:

- **Popülasyon = Bütün kek**
- **Örneklem = Kekten alınan bir dilim**

  🍰 Dilim, kekin tamamını temsil ederse, kek hakkında fikir sahibi olabiliriz.

Merkezi Yönelim (Merkezi Eğilim) Ölçüleri Nedir?

(Measure of Central Tendency)

Bir veri grubunda değerler dağılmış olsa da, genellikle **ortalarda bir yerde yoğunlaşırlar**.

İşte verilerin bu **"merkezde toplanma eğilimini"** gösteren istatistiksel ölçülere **merkezi yönelimin ölçüleri** denir.

Bunlar verilerin **tipik değerini** bulmamıza yarar.

🔑 Temel Ölçüler:

1. Aritmetik Ortalama (Mean)

- Tüm değerlerin toplamının, değer sayısına bölünmesiyle bulunur.

Örneklem Ortalaması → $\bar{X}$

Formül:

$$\bar{X} = \frac{\sum X_i}{n}$$

$\bar{X}$: Örneklem ortalamasını ifade eder.

∑: Toplama işareti

X: Değer

n: Veri sayısı(kaç tane değer var?)

Not: Burada kullandığımız sembol örneklemin ortalamasını hesaplamak için kullanılır.

Örnek:

Sınav notları: 60, 70, 80

Ortalama = (60 + 70 + 80) ÷ 3 = 70

Popülasyon Ortalaması → μ (mü)

$$\mu = \frac{\sum X_i}{N}$$

- **μ (mü)**: Popülasyonun gerçek ortalamasını ifade eder.
- **∑:** Toplama işareti
- **X:** Değer
- **N**: Popülasyondaki toplam birim sayısıdır. (n)
- Bu genellikle **bilinmez**, çünkü tüm popülasyonun verilerine ulaşmak zordur.

📌 **Çok basit örnek:**

Bir okulda **tüm öğrencilerin boy ortalaması** aslında μ'dir.

Ama biz sadece 30 öğrencinin boyunu ölçtük → onların ortalaması X¯'tir.

👉 Yani:

- μ = tüm okulun boy ortalaması
- X¯ = seçtiğimiz sınıfın ortalaması (μ'yü tahmin eder).

2. Medyan-Ortanca(Median)

- Veriler **küçükten büyüğe** sıralandığında **tam ortadaki değer** medyandır.
- Eğer değer sayısı çiftse, ortadaki iki sayının ortalaması alınır.

Örnek:

Notlar: 40, 50, 60, 70, 100

Medyan = 60 (ortadaki değer)

Değer sayısı çiftse:

Notlar: 40, 50, 60, 70

Medyan = (50 + 60) ÷ 2 = 55

📌 Outlier (Aykırı Değer) Nedir?

- Veri grubunun geri kalanına göre **çok küçük** veya **çok büyük** olan uç değerlerdir.
- Örn: Sınıftaki notlar → 40, 45, 50, 55, 60, **100**

  Burada **100** diğerlerinden çok farklı → outlier değer.

📌 Medyanın Outlier Durumunda Avantajı

- **Medyan**, veriler küçükten büyüğe sıralandığında **ortadaki değeri** alır.
- Yani sadece ortadaki konuma bakar, uç değerlerin büyüklüğünden **etkilenmez**.

🔍 Örnek Karşılaştırma

Veriler: 10, 12, 13, 14, 15

- Ortalama = (10+12+13+14+15) / 5 = **12.8**
- Medyan = **13**

Şimdi bir outlier ekleyelim: 10, 12, 13, 14, **100**

- Ortalama = (10+12+13+14+100) / 5 = **29.8** (uç değer ortalamayı çok şişirdi 🚨)
- Medyan = **13** (hiç değişmedi ✅)

📌 Sonuç

- **Medyan**, outlier olduğunda verilerin merkezini daha güvenilir şekilde gösterir.
- O yüzden **gelir, fiyat, sınav notu** gibi uç değerlerin olabileceği yerlerde medyan tercih edilir.

3. Mod-Tepe Değer(Mode)

- Bir veri grubunda **en sık tekrar eden değer**dir.

Örnek:

Notlar: 50, 60, 60, 60, 70, 70, 80, 90

Mod = 60 (çünkü en çok tekrar eden değer bu).

Yayılımın Ölçüleri Nedir?

(Measure of Dispersion)

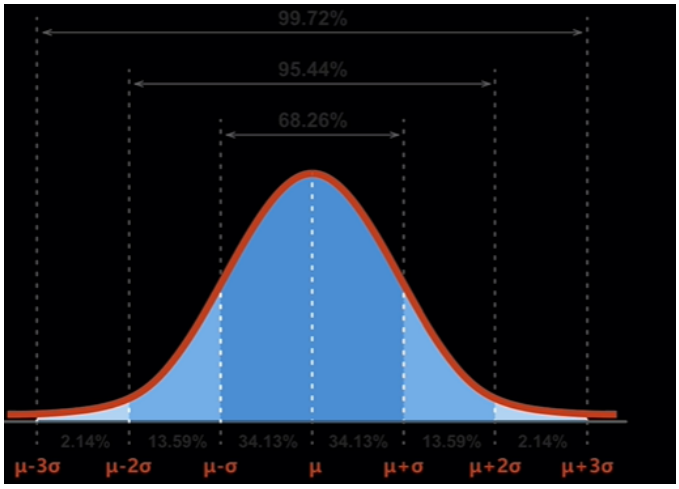

Bir veri grubunda sadece **merkez (ortalama, medyan, mod)** değil, aynı zamanda **değerlerin ne kadar dağıldığı** da önemlidir.

👉 İşte bu dağılımı, yani verilerin merkezden **ne kadar uzaklaştığını veya birbirine ne kadar yakın olduğunu** gösteren ölçülere **yayılım ölçüleri** denir.

🔑 Temel Yayılım Ölçüleri:

1. Varyans(Variance)

- Varyans, verilerin **ortalama etrafında ne kadar dağıldığını** gösteren bir yayılım ölçüsüdür.
- Yani verilerin **merkezden (ortalama) sapmalarının karelerinin ortalamasıdır**.

Popülasyon Varyansı (σ2)

- Popülasyon varyansı, **tüm popülasyon verileri** kullanılarak hesaplanır.
- Formül:

$$\sigma^2 = \frac{\sum (X_i - \mu)^2}{N}$$

X_i → Her bir veri

μ → Popülasyon ortalaması

N → Popülasyondaki veri sayısı

📌 Örnek:

Popülasyon verileri: 2, 4, 6

- Ortalama $\mu = (2 + 4 + 6)/3 = 4$
- Varyans $\sigma^2 = [(2-4)^2 + (4-4)^2 + (6-4)^2]/3 = (4 + 0 + 4)/3 = 2.67$

Örneklem Varyansı (s2)

- Örneklem varyansı, **popülasyonu temsil eden küçük bir grup veriden** hesaplanır.
- Formül:

$$s^2 = \frac{\sum(X_i - \bar{X})^2}{n-1}$$

$\bar{X}$ → Örneklem ortalaması

n → Örneklem sayısı

n-1 kullanılır çünkü küçük örneklem popülasyon varyansını **hafifçe küçültür**, "düzeltme" yapılır (Bessel düzeltmesi).

📌 Örnek:

Örneklem verileri: 2, 4, 6

- Örneklem ortalaması $\bar{X} = 4$
- Örneklem varyansı $s^2 = [(2-4)^2 + (4-4)^2 + (6-4)^2]/(3-1) = 8/2 = 4$

✅ Dikkat: Örneklem varyansı genellikle **popülasyon varyansından biraz daha büyük çıkar**, çünkü küçük örneklem popülasyonu tam temsil etmez.

Değişken Tipleri Nelerdir?

Değişken Nedir?

- **Değişken**, araştırmada incelenen **özellik veya nitelik**tir.
- Kısaca: **Kişiden kişiye, durumdan duruma farklı değerler alabilen şeydir.**
- Aynı özelliğe bakarız ama farklı kişilerde farklı sonuçlar görürüz.

👉 Örneğin:

- İnsanların **yaşı** → 20, 25, 30 ...
- Öğrencilerin **sınav notları** → 50, 70, 100 ...
- Katılımcıların **cinsiyeti** → Kadın, Erkek

Bunların hepsi **değişken**dir çünkü her bireyde farklı değer alır.

📊 Değişken Tipleri

1️⃣ Nitel (Kategorik) Değişkenler

- Sayısal değil, **grupları/kategorileri** gösterir.
- Matematiksel işlem yapılamaz (toplama, çıkarma gibi).

🔹 **Alt türleri:**

- **Nominal:** Sadece isim/etiket → sıralama yok.
  - Örn: Cinsiyet (Kadın/Erkek), Renk (Kırmızı/Mavi/Yeşil)
- **Ordinal (Sıralı):** Kategoriler arasında sıralama var ama farkın büyüklüğü ölçülmez.
  - Örn: Eğitim seviyesi (İlkokul < Lise < Üniversite), Memnuniyet (Az – Orta – Çok)

2️⃣ Nicel (Sayısal) Değişkenler

- Sayısal değerler alır, matematiksel işlem yapılabilir.

🔹 **Alt türleri:**

- **Kesikli (Discrete):** Belirli tam sayılar alır.
  - Örn: Çocuk sayısı (0, 1, 2...), Kitap sayısı (5, 10...)
- **Sürekli (Continuous):** Bir aralıkta **her değeri** alabilir.
  - Örn: Boy (165.4 cm olabilir), Ağırlık, Sıcaklık, Gelir

📌 Özet Tablo:

Değişken Türü	Alt Tür	Örnek
Nitel	Nominal	Renk, Cinsiyet
	Ordinal	Eğitim seviyesi, Memnuniyet
Nicel	Kesikli	Çocuk sayısı, Kitap sayısı
	Sürekli	Boy, Kilo, Gelir, Sıcaklık

Rastgele Değişken Nedir?

- **Rastgele değişken**, olasılık kuramında tanımlanan özel bir değişkendir.
- Bir **rastgele deneyin sonucu** olarak sayısal değer alır.
- Yani deneme yapılmadan sonucu bilinmez → **tesadüfi** (rastgele) → ama gerçekleştiğinde belli bir **sayısal değer** alır.

👉 Basitçe:

Rastgele deney = Zar atmak, para atmak, sınavda puan almak...

Rastgele değişken = O deneyin sayısal sonucu.

📊 Türleri

1️⃣ Ayrık (Kesikli) Rastgele Değişken

- Sonuçlar **sayılabilir**.
- Örn:
  - Zar atışında gelen sayı (1, 2, 3, 4, 5, 6)
  - 10 kişilik sınıfta derse gelmeyen öğrenci sayısı (0–10 arası tam sayılar)

2️⃣ Sürekli Rastgele Değişken

- Sonuçlar **bir aralıktaki her değeri** alabilir.
- Örn:

- Bir insanın boyu (170.3 cm olabilir)
- Sınav süresince öğrencinin harcadığı zaman (örneğin 32.6 dakika olabilir)

🔑 Farkı Daha Basitçe

- **Değişken**: Kişiden kişiye/durumdan duruma değişen özellik (örneğin "boy" bir değişkendir).
- **Rastgele değişken**: Bir olasılık deneyinin sonucu olarak sayısal değer alan değişken (örneğin "zarın sonucu" bir rastgele değişkendir).

📌 **Örnek:**

- Para atma → Rastgele deney
- Tura = 1, Yazı = 0 dersek → “X = gelen yüz” bir **rastgele değişkendir**.